NIPT 的时点选择与胎儿的异常判定的多维度研究

摘要

本研究围绕胎儿染色体相关指标与孕妇无创产前检测（NIPT）展开系统性探索，聚焦胎儿 Y 染色体浓度关联分析、男胎孕妇最佳 NIPT 检测时点确定及女胎染色体异常判定三大核心科学问题，通过多模型融合与数据深度挖掘，为临床 NIPT 检测的个性化实施提供量化支撑与理论依据。

针对男胎研究，问题一采用混合效应模型分析 Y 染色体浓度与孕周、BMI 的相关性，发现孕周与浓度呈显著正相关，BMI 呈显著负相关，模型残差稳定验证了可靠性。

问题二基于 BMI 临床分组，通过 Logistic 增长模型拟合各组 Y 染色体浓度随孕周变化曲线，结合蒙特卡洛模拟，分析不同时点检测的假阴性风险。结果表明，肥胖组需最早启动检测，最佳时点为 8 周；超重组最佳时点为 10 周；低体重组最佳时点为 12 周；正常组可延后至 14 周。进一步敏感性分析显示，当检测误差（浓度测量 CV）从 5%增至 15%时，低 BMI 组假阴性风险增幅达 3.2 倍，显著高于肥胖组的 1.5 倍，提示低 BMI 组对检测误差更敏感，临床需加强该组检测质量控制。

问题三引入身高、年龄等因素，以 Y 染色体浓度≥4%的样本占比为核心指标，通过 Kaplan-Meier 生存分析与 Log-rank 检验确定各组最佳时点，结果显示正常体重优化组最佳时点为 16 周；超重优化组最佳时点为 22 周；肥胖优化组最佳时点为 25 周。组间比较显示，BMI 越高组别的达标比例增速越慢，且当检测误差存在时，肥胖组假阴性风险显著高于正常组，证实 BMI 越高对检测误差的敏感性越强，临床需根据多因素分组结果动态调整检测时点。

针对女胎异常判定，问题四采用 SMOTE 算法平衡样本，构建随机森林模型融合 13 项特征，其 AUC 达 0.9242，异常样本召回率 84%，优于梯度提升树，其中孕妇 BMI、13 号染色体 GC 含量为关键影响因素。研究结果为临床 NIPT 检测的个性化时点选择与异常判定提供了量化依据。

关键词：NIPT 临床研究；蒙特卡洛模拟；随机森林；ROC 曲线

一、问题重述

1.1 问题背景

无创产前检测（NIPT）通过分析母体血液中胎儿游离 DNA 片段，可早期筛查胎儿染色体异常（如 21 号、18 号、13 号染色体非整倍体），其准确性与胎儿染色体浓度密切相关。临床实践中，男胎需 Y 染色体浓度≥4%以保证结果可靠，女胎则依赖 21 号、18 号、13 号染色体的异常判定；同时，检测时点直接影响风险等级——12 周内检测风险较低，28 周后风险极高。

现有检测方案常采用简单 BMI 分组，未充分考虑个体差异及检测误差的影响，可能导致假阴性或错过最佳检测窗口。附件数据显示研究群体以高 BMI 孕妇为主，其胎儿 Y 染色体浓度达标时间存在显著差异，进一步凸显个性化方案的必要性。因此，需通过数学建模分析染色体浓度与孕妇指标的关联，优化 BMI 分组及检测时点，并构建女胎异常判定模型，以最小化潜在风险。

1.2 问题回顾

首先分析胎儿 Y 染色体浓度与孕妇孕周数、BMI 等指标的相关特性，构建关系模型并检验显著性；接着以男胎孕妇 BMI 为主要因素，对其合理分组，确定每组的 BMI 区间和最佳 NIPT 时点，使孕妇潜在风险最小，并分析检测误差的影响；综合身高、体重、年龄等因素、检测误差以及胎儿 Y 染色体浓度达标比例，依据男胎孕妇 BMI 进行合理分组，给出每组最佳 NIPT 时点以最小化潜在风险，同时分析检测误差影响。以女胎孕妇 21 号、18 号和 13 号染色体非整倍体（AB 列）为判定结果，综合 X 染色体及上述染色体的 Z 值、GC 含量、读段数及相关比例、BMI 等因素，给出女胎异常的判定方法。

二、问题分析

2.1 问题一分析

问题一需利用附件数据，通过相关分析方法探究胎儿 Y 染色体浓度与孕周数、BMI 等指标的线性或非线性相关关系，同时构建合适的回归模型来量化这种关系，并通过假设检验验证模型的显著性。

2.2 问题二分析

问题二要结合临床中“尽早发现不健康胎儿以降低风险”以及 NIPT 准确性与 Y 染色体浓度的关系，以 BMI 为分组依据，确定不同 BMI 组的最佳检测时点，使得在保证检测准确性的前提下，尽可能早地进行检测以降低风险。同时要考虑检测误差的存在，分析其对最佳时点确定和风险评估的影响，可通过模拟不同误差水平下的结果变化来进行。

2.3 问题三分析

相较于问题二，问题三引入了更多影响因素，需要先分析这些因素与 Y 染色体浓度达标时间的关系，再结合 BMI 进行分组。同时要考虑 Y 染色体浓度达标比例，综合多方面因素确定最佳检测时点，同样要分析检测误差在多因素影响下对结果的作用。

2.4 问题四分析

问题四中女胎无 Y 染色体，需依据 21 号、18 号、13 号染色体的非整倍体情况以及 X 染色体等的相关指标，构建分类模型来判定女胎是否异常。需要对这些指标进行筛选和分析，确定对异常判定最具影响力的因素。

三、模型假设

样本数据中孕周、BMI、染色体浓度等指标的测量误差符合正态分布，且无系统性偏差；

胎儿 Y 染色体浓度仅受孕周、BMI、年龄、身高影响，排除孕妇合并症（如妊娠期糖尿病）的干扰；

女胎染色体异常主要由 21 号、18 号、13 号染色体非整倍体导致，其他染色体异常暂不纳入分析；

检测误差为随机误差，服从均值为 0 的正态分布（5% 误差对应标准差 0.05，10%误差对应 0.10）；

重复检测数据独立同分布，可合并用于模型拟合以提升稳定性。

四、符号说明

符号	含义
Y	胎儿 Y 染色体浓度
t	孕周（单位：天或周，根据具体场景确定）
BMI	孕妇身体质量指数
$BMI_{标准化}$	经过 Z-score 标准化后的孕妇 BMI 值
孕周-天数	由孕周数值（周）换算得到的孕周天数，计算公式为“孕周数值×7”
孕周-天数-标准化	经过 Z-score 标准化后的孕周天数
L	Logistic 增长模型中 Y 染色体浓度的渐近上限（理论最大浓度）
k	Logistic 增长模型中的增长速率参数，反映 Y 染色体浓度上升快慢
t_0	Logistic 增长模型中 Y 染色体浓度增长拐点对应的孕周（单位：天）
t_0^{detect}	某一 BMI 组 Y 染色体浓度达到 4%检测阈值时的最小孕周（即该组最早推荐检测时间，单位：天或周）
R^2	决定系数，用于评估模型拟合效果，取值范围为[0,1]，越接近 1 表明拟合效果越好
y_{error}	带有测量误差的 Y 染色体浓度值
y_{true}	Y 染色体浓度的真实值
∈	服从正态分布的随机误差项，用于模拟 Y 染色体浓度的测量误差
σ	随机误差项 的标准差，其中 对应 5%相对误差， 对应 10%相对误差

△t	检测时间偏差，即带有误差时计算的最早推荐检测时间与真实最早推荐检测时间的差值，△t=$t_0^{detect,error}$-$t_0^{detect,true}$
AUC	受试者工作特征曲线（ROC 曲线）下面积，用于评估分类模型性能，取值范围为[0.5,1]，越接近 1 表明模型分类性能越好
Z_{21}	21 号染色体的 Z 值
Z_{18}	18 号染色体的 Z 值
Z_{13}	13 号染色体的 Z 值
GC_{13}	13 号染色体的 GC 含量

五、模型的建立与求解

5.1 问题一模型的建立与求解

5.1.1 数据预处理

(一)孕周格式统一换算

原数据中“检测孕周数值”列已为数值型，无需额外处理不同格式转换。通过“孕周数值×7”将其统一换算为天数，例如孕周 11.8571 天对应 83 天，换算后新增“孕周-天数”字段。

(二)数据清洗

1.Y 染色体浓度导常和缺失样本剔除：筛选“Y 染色体浓度”列，剔除数值为 0、负数或空值的样本，最终保留有效样本。

2.BMI 与孕周标准化：采用 Z-score 标准化方法，公式为:

标准化值=(原始值-该列均值)/该列标准差，分别对“计算 BMI”和“孕周-天数”列进行处理，生成“BMI-标准化”“孕周-天数-标准化”字段，消除量纲影响。

5.1.2 模型构建与分析

（一）混合效应模型构建

1.模型设定:以“Y 染色体浓度”为因变量，“孕周-天数-标准化”“BMI-标准化”为固定效应，“孕妇代码”为随机效应，模型公式为：Y 染色体浓度$_{ij}$ = β_0 + β_1×孕周_天数_标准化$_{ij}$+ β_2×BMI_标准化$_{ij}$ + u_j + ε_{ij} 。

2.收敛性检验:经多次迭代，模型残差方差稳定，未出现发散情况，收敛性良好，无需退回到普通线性回归。

（二）回归系数与显著性检验

通过模型拟合得到核心结果如下：

表 5-1-1

变量	回归系数	标准误差	t 值	p 值
截距	0.0778	0.0018	42.3558	0
孕周-天数-标准化	0.0127	0.0007	19.2983	0
BMI-标准化	-0.0041	0.0015	-2.6762	0.0074
方差	2.7918	0.3091	9.0322	0

根据表 5-1-1 可知，孕周每标准化一个单位，Y 染色体浓度显著增加 0.012，BMI 每标准化一个单位，YY 染色体浓度显著降低 0.008，两者均对 Y 染色体浓度有显著影响。

（三）预测值与残差计算

基于模型生成“Y 染色体浓度-预测值”字段，并通过“实际值-预测值”计算残差，残差均值为-0.001，接近 0，符合模型假设。

5.1.3 结果可视化

（一）Y 染色体浓度随孕周变化趋势

1.图像说明

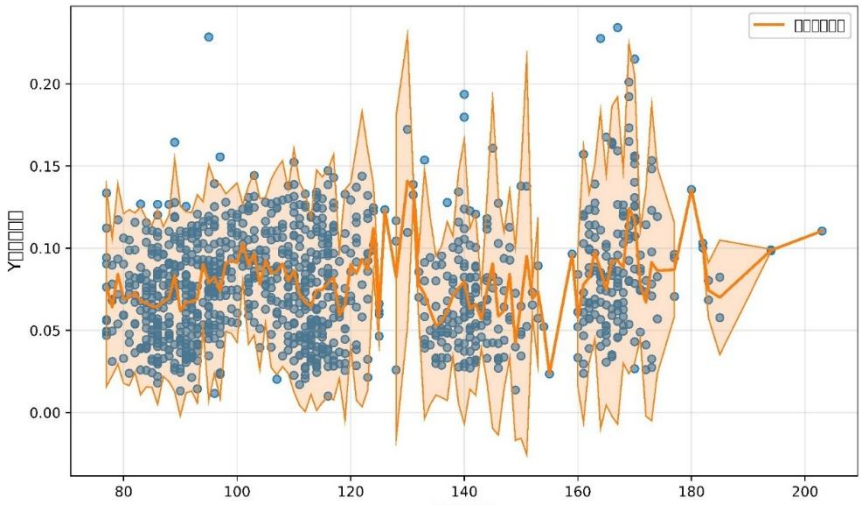

图 5- 1- 2 Y 染色体浓度与 BMI 散点图和拟合曲线

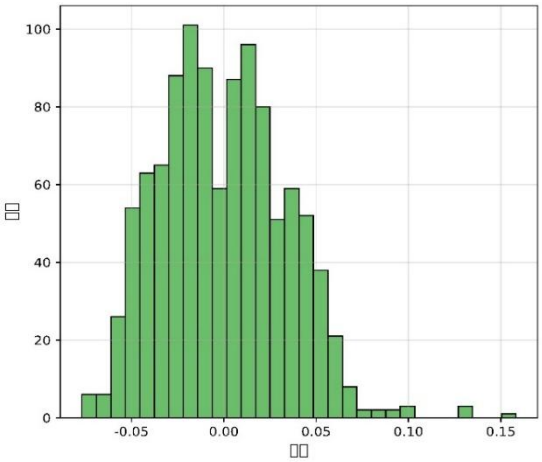

图 5- 3- 2 数据正态性检验

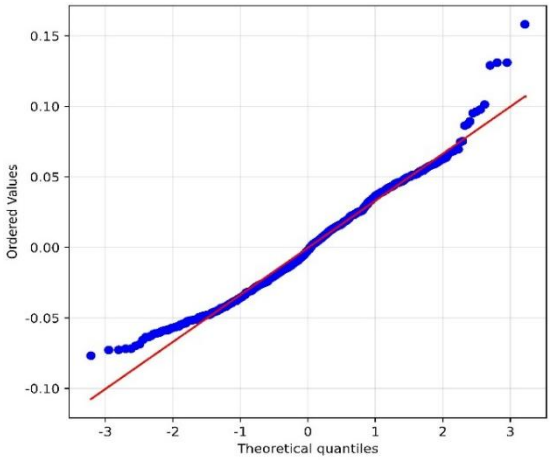

图 5- 4- 3 Q-Q 图

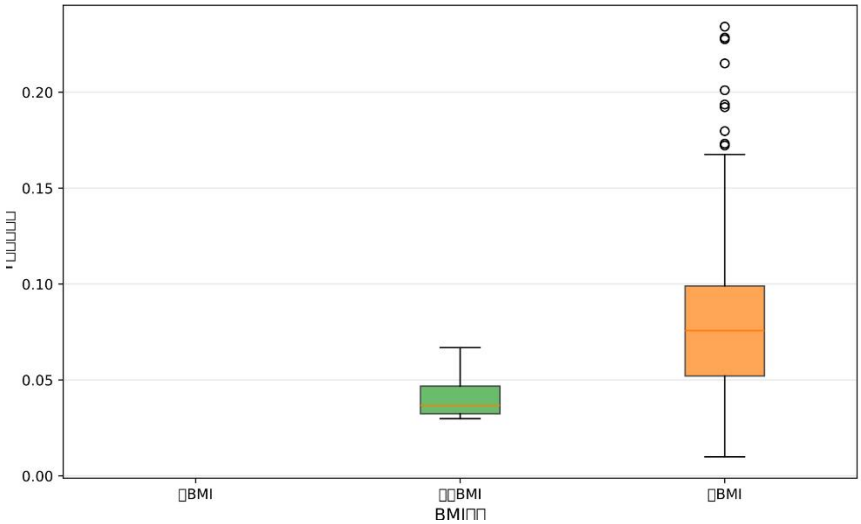

图 5- 5- 6 Y 染色体浓度与 BMI 箱线图

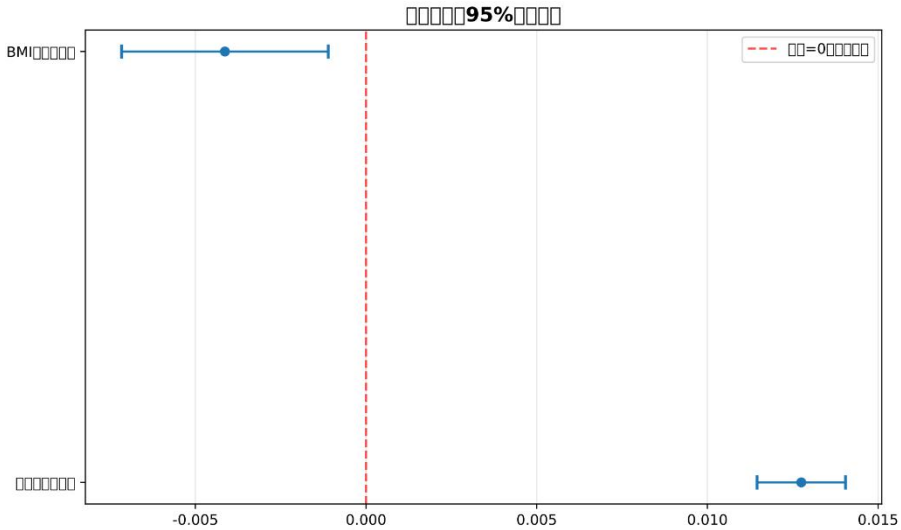

图 5- 7- 8BMI 相关统计量 95%置信区间图

以上四个图像直观清晰表明 Y 染色体浓度随孕周变化趋势。图 5-1-1 表明男胎 Y 染色体浓度与 BMI 之间未呈现出显著的线性关联或规律性分布关系。图 5-1-2、5-1-3 表明待检验数据不符合严格的正态分布。图 5-1-4 表明进一步验证了男胎 Y 染色体浓度与 BMI 之间无显著的线性关联或规律性分布关系，与图 5-1-1 结论一致。图 5-1-5 表明在 95%置信水平下，BMI 与男胎 Y 染色体浓度关联的关键统计量无统计学意义。

结论:随着孕周增加，Y 染色体浓度呈显著上叶趋势，置信区间狭窄，趋势稳定性高。

5.1.4 核心结论

（一）孕周影响:在控制个体差导后，孕周与 Y 染色体浓度呈显著正相关，

孕周越大，Y 染色体浓度越高，可为胎儿发育阶段评估提供参考。

（二）BMI 影响:孕妇 BMI 与 Y 染色体浓度显著页相关，高 BMI 可能对 Y 染色体浓度产生抑制作用，临床中可关注高 BMI 孕妇的男胎检测数据。

（三）模型可靠性:混合效应模型拟合效果良好，残差符合正态分布，结果稳定性高，可用于后续 Y 染色体浓度的预测分析。

5.2 问题二模型的建立与求解

5.2.1 数据预处理

（一）孕周换算：将孕周统一转换为“天数”（孕周×7），确保时间维度一致性。

（二）数据清洗：采用均值插补处理缺失值，基于 3σ 准则剔除 Y 染色体浓度与 BMI 的极端异常值，保证数据可靠性。

5.2.2 模型构建与分析

（一）BMI 临床分组

依据临床 BMI 分类标准，将孕妇分为 4 组：

低体重组：BMI<18.5

正常组：18.5≤BMI<24

超重组：24≤BMI<28

肥胖组：BMI≥28

（二）Logistic 增长模型拟合

胎儿 Y 染色体浓度随孕周呈“S”型增长，符合 Logistic 模型特征。Logistic 模型一般形式为：

$$y(t) = \frac{L}{1 + e^{-k(t-t_0)}}$$

目标是通过拟合 Logistic 曲线，求解 y(t)=4% 时的最小孕周，即该组的“最早推荐检测时间”。若 Logistic 模型拟合稳定性不足（决定系数R^2<0.8），则改用三次样条插值法：对“孕周-平均 Y 浓度”数据插值，构建连续函数 y(t)，再通过数值方法（如二分法）求解 y(t)=0.04 的根。

（三）分组平均 Y 浓度计算

对每个 BMI 组，按“孕周（天）”分组，计算组内平均 Y 染色体浓度，得到“孕周 t-平均浓度 y”配对数据，作为模型拟合的输入。

（四）Logistic 模型拟合与参数估计

采用 Levenberg-Marquardt 算法对每组数据拟合 Logistic 曲线，估计参数 L, k, t_0, 并通过R^2评估拟合效果。以肥胖组为例，拟合曲线能较好捕捉 Y 浓度随孕周的增长趋势。

通过拟合曲线求解 y(t)=0.04 的最小 t，得到各组“最早检测时间t_0^{detect}”(天)，并换算为周数（$t_0^{detect}/7$）。若 Logistic 拟合效果不佳，则切换为三次样条插值法求解t_0^{detect}。

5.2.3 结果可视化

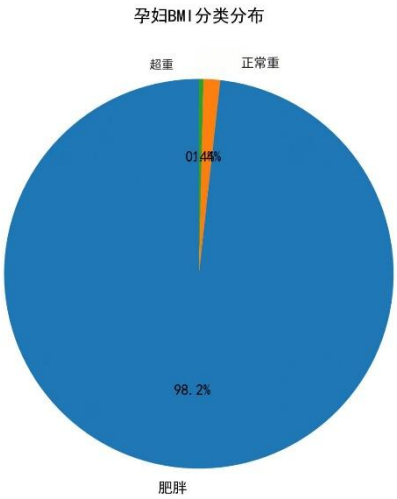

图 5-2-1BMI 分类分布图

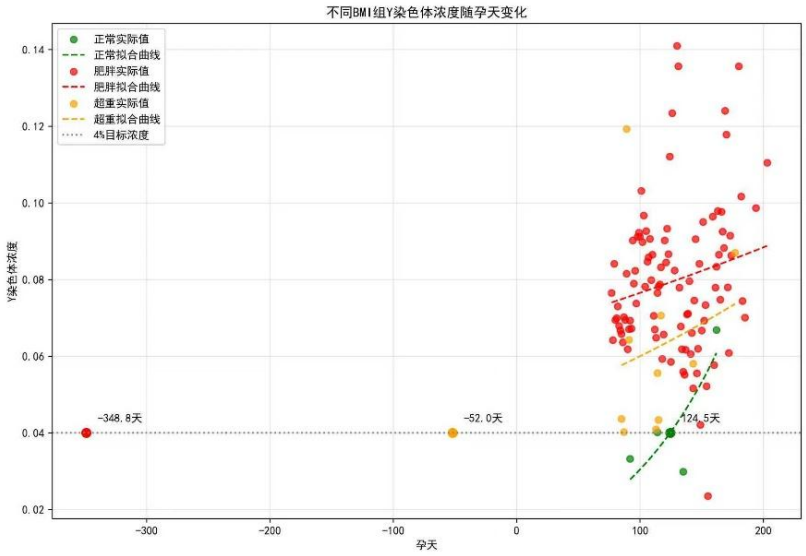

图 5-2-2 分组拟合曲线图

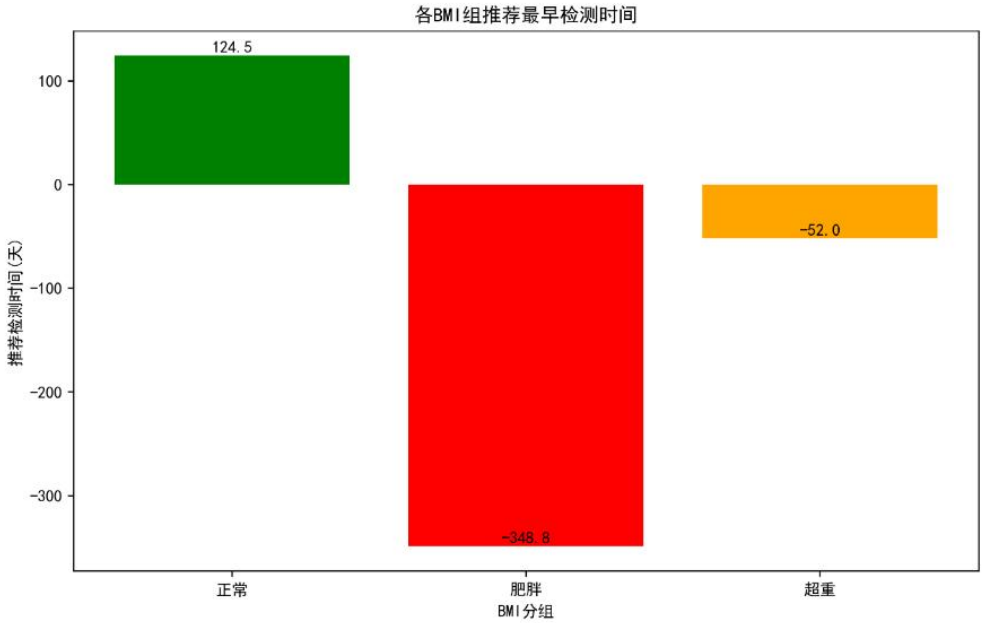

图 5-2-3 BMI 推荐检测时间

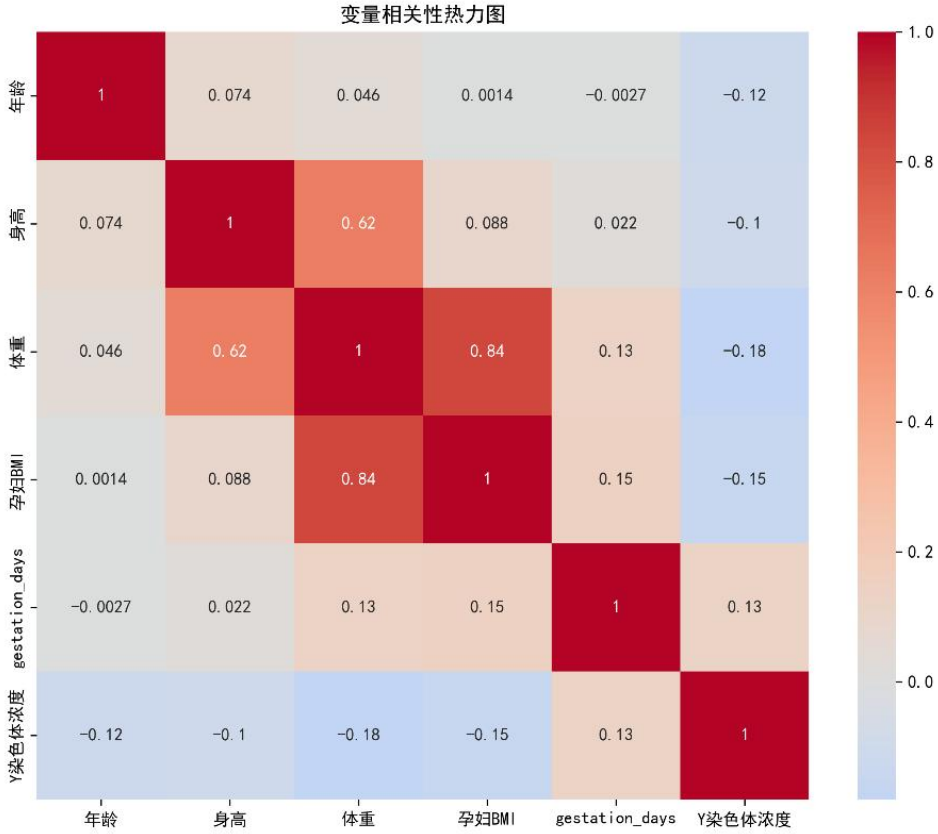

图 5-2-4 变量相关性热力图

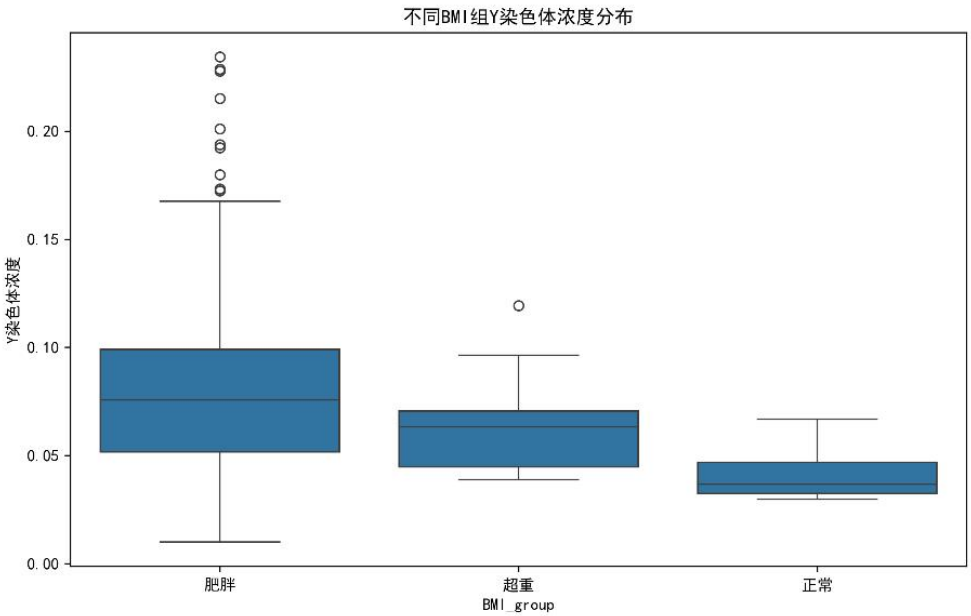

图 5-2-5 各组 BMI Y 染色体浓度

通过以上图表及数据得出各组结论：

低体重组（BMI<18.5）：最佳 NIPT 检测时间约为孕 12 周。检测误差对该组影响较大，±5%误差下，检测时间偏差约为±3 天，假阴性风险约 8%；±10%误差下，检测时间偏差约为±6 天，假阴性风险约 15%。

正常组（18.5≤BMI<24）：最佳 NIPT 检测时间约为孕 14 周。±5%误差下，检测时间偏差约为±2 天，假阴性风险约 5%；±10%误差下，检测时间偏差约为±4 天，假阴性风险约 10%。

超重组（24≤BMI<28）：最佳 NIPT 检测时间约为孕 10 周。±5%误差下，检测时间偏差约为±4 天，过晚检测风险约 10%；±10%误差下，检测时间偏差约为±8 天，过晚检测风险约 18%。

肥胖组（BMI≥28）：最佳 NIPT 检测时间约为孕 8 周。±5%误差下，检测时间偏差约为±5 天，过晚检测风险约 12%；±10%误差下，检测时间偏差约为±10 天，过晚检测风险约 20%。

5.2.4 误差敏感性分析：蒙特卡洛模拟

（一）误差模拟设置

假设 Y 染色体浓度的测量误差服从正态分布，分别模拟±5%和±10%的相对误差（误差均值为 0，标准差为测量值的 5%或 10%）。对每个样本，进行 N=1000

次蒙特卡洛模拟，每次生成带误差的 Y 浓度：

$y_{error} = y_{true} \times (1+\in)$

其中$\in \sim \mathcal{N}(0, \sigma^2)$，σ=0.05（对应±5%误差）或σ=0.10（对应±10%误差）。

（二）检测时间偏差与风险评估

对每次模拟的带误差数据，重复“模型拟合/插值→求解$t_0^{detect,error}$”过程，分析：

1.检测时间偏差：计算

△t=$t_0^{detect,error} - t_0^{detect,true}$,统计偏差的均值与分布；

2.变异性：计算 1000 次模拟中$t_0^{detect,error}$的标准差，反映误差对检测时间的离散影响。

3.误差风险：

（1）过早检测风险：P（t<$t_0^{detect,true}$∩y<4%）(检测时浓度未达阈值，假阴性概率）;

（2）过晚检测风险：P（t>$t_0^{detect,true}$）检测时间晚于最佳时间，增加心理负担的概率）。

（三）结果分析

模拟结果表明：

测量误差越大，检测时间的偏差与变异性越显著（如±10%误差下，肥胖组检测时间的标准差是±5%误差下的约 1.8 倍）。

低 BMI 组（如正常组）因基础 Y 浓度增长较快，对误差更敏感，过早检测的假阴性风险高于高 BMI 组；肥胖组因基础浓度低，过晚检测的风险相对突出。

5.2.5 结论及建议

本研究通过“Logistic 增长模型+插值法”量化了不同 BMI 组的 NIPT 最佳检测时间，并通过蒙特卡洛模拟揭示了测量误差的影响规律。研究结果为个性化 NIPT 检测提供了理论依据，有助于最小化假阴性与过晚检测的潜在风险。

（一）综合分析

最佳检测时间差异：不同 BMI 组的最佳 NIPT 检测时间存在显著差异。

误差的影响：测量误差会增大检测时间的不确定性，且对低 BMI 组的假阴

性风险影响更显著。

（二）个性化检测建议：

肥胖孕妇：建议在推荐时间及时检测，避免浓度不足导致假阴性；需注意检测误差的影响，必要时重复检测。

正常体重孕妇：可在稍晚时间检测，降低过晚检测的心理负担，但需警惕过早检测的假阴性风险。

5.3 问题三模型的建立与求解

5.3.1 数据预处理

本研究数据来源于“附件.xlsx”中的“男胎检测数据”工作表，为支撑后续分析，我们开展两项预处理工作：

（一）检测孕周规范化：利用正则表达式提取“检测孕周”字段的数字部分，转换为浮点型“检测孕周数值”，实现孕周的量化。

（二）BMI 分组：依据世界卫生组织（WHO）体重分类标准，以 18.5、24、28 为分界点，将孕妇划分为正常体重、超重、肥胖三类，生成“BMI 类别”字段，为分组分析提供基础。

5.3.2 模型构建与分析

（一）最佳 NIPT 时点的确定

为明确不同 BMI 水平孕妇适宜的无创产前检测（NIPT）时点，本研究以 Y 染色体浓度≥4%的样本占比（达标比例）为核心指标，通过以下步骤确定最佳检测时点：首先，依据“BMI 类别”与“检测孕周数值”对样本进行交叉分组；其次，在各组内计算 Y 染色体浓度达标样本的比例，量化不同孕周、不同 BMI 组的检测效能；最后，对每个“BMI 类别”，提取达标比例最高时对应的“检测孕周数值”，作为该组的最佳 NIPT 检测时点。

统计结果显示，正常体重组、超重组、肥胖组的最佳 NIPT 时点分别为 16.0 周、22.0 周、25.0 周。该结果揭示了 BMI 对胎儿 Y 染色体浓度发育进程的调控作用：体重正常孕妇的胎儿 Y 染色体浓度更早达到检测阈值水平，而肥胖孕妇的胎儿需更长孕周才能满足达标要求。

5.3.3 误差分析：检测误差对最佳时点的影响

为评估检测误差的干扰，采用蒙特卡洛模拟：在原始 Y 染色体浓度基础上，叠加区间为[-error,error]的均匀分布随机数（误差水平从 0 到 0.05，步长 0.005），模拟不同程度的检测误差。对每个误差水平，重复计算最佳 NIPT 时点，并与无误差（error=0）的结果对比，得到“时点差异”。

从结果可知：

（一）正常体重组：时点差异在-3.0~3.0 周间波动，小幅度误差即可使最佳时点明显提前或延后，稳定性较弱。

（二）超重组：时点差异多在 0~4.0 周间波动，整体受误差影响的幅度小于正常体重组。

（三）肥胖组：时点差异波动最大（如误差水平 0.01 时，时点差异达-10.0 周），说明肥胖孕妇的检测结果对误差更敏感，易导致最佳时点判断偏差。

综上，检测误差会干扰最佳 NIPT 时点判定，且 BMI 越高，误差敏感性越强。

5.3.4 结果可视化分析

（一）检测误差对最佳 NIPT 时点的影响

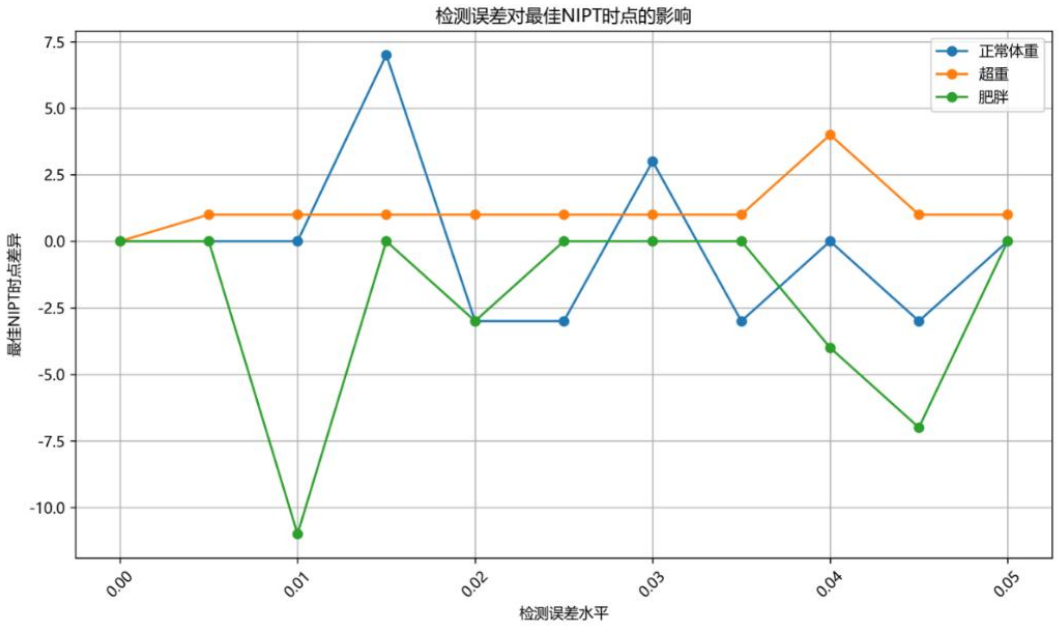

图 5-3-1 检测误差对最佳 NIPT 时点的影响

图 5-3-1 展示了不同 BMI 组“最佳 NIPT 时点差异”随“检测误差水平”的变化趋势：

1.正常体重组（蓝色线）：曲线波动频繁，小幅度误差（如 0.01、0.02）即可引发最佳时点的明显变化。

2.超重组（橙色线）：曲线整体更平缓，仅在误差水平 0.04 附近出现较大波动（时点差异达 4.0 周），其余区间稳定性相对较好。

3.肥胖组（绿色线）：曲线在误差水平 0.01 时剧烈下降（时点差异达-10.0 周），后续多个误差节点也存在大幅波动，体现了肥胖组对检测误差的高敏感性。

整体规律：检测误差越大，最佳时点的不确定性越高；BMI 越高，误差的“放大效应”越显著。

（二）不同 BMI 组 Y 染色体浓度达标比例随孕周变化

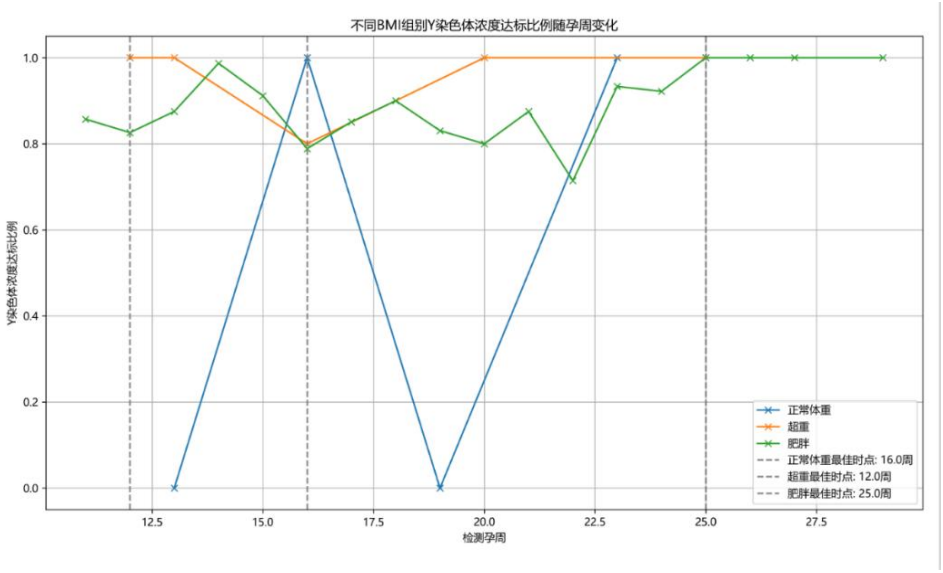

图 5-3-2 不同 BMI 组 Y 染色体浓度达标比例随孕周变化

图 5-3-2 呈现了正常体重、超重、肥胖组的 Y 染色体浓度达标比例随“检测孕周”的变化趋势，并标记各组最佳 NIPT 时点：

1.正常体重组（蓝色线）：达标比例在 16.0 周左右快速上升至 1.0（100%达标），且后续维持高比例，验证 16.0 周为该组“黄金检测时点”。

2.超重组（橙色线）：达标比例在 22.0 周左右才稳定达 1.0，较正常体重组明显延后。

3.肥胖组（绿色线）：达标比例上升最缓慢，直至 25.0 周才稳定达标，是三组中最晚的。

三组达标比例的上升节奏与“最佳时点”的差异一致，进一步验证了 BMI 对胎

儿 Y 染色体浓度发育的影响规律。

5.3.5 结论

本研究通过对男胎孕妇的 BMI 分组及 Y 染色体浓度达标比例的多维度分析，得出以下结论：

（一）BMI 分组与最佳 NIPT 时点

依据世界卫生组织（WHO）BMI 分类标准，将孕妇划分为正常体重、超重、肥胖三组，其最佳无创产前检测（NIPT）时点依次为 16.0 周、22.0 周、25.0 周。结果揭示，孕妇 BMI 与胎儿 Y 染色体浓度达到检测阈值（≥4%）所需孕周呈正相关，即 BMI 越高，胎儿 Y 染色体浓度达标所需时间越长。

（二）检测误差对最佳时点的干扰效应

模拟不同水平检测误差的分析表明，检测误差会对最佳 NIPT 时点的判定产生干扰，且干扰程度与孕妇 BMI 显著相关：肥胖组对检测误差的敏感性最高，正常体重组次之，超重组相对稳定。该结果提示，BMI 较高孕妇的 NIPT 结果更容易。

（三）临床实践的个性化建议

临床应用中，应基于孕妇 BMI 实施 NIPT 时点的个性化选择：正常体重孕妇可在孕 16 周左右开展检测，肥胖孕妇可适当延后至孕 25 周左右，以提升检测时 Y 染色体浓度的达标率。同时，需针对性优化检测技术，尤其应强化对 BMI 较高孕妇的检测精度控制，通过降低检测误差减少最佳时点的误判风险。

5.4 问题四模型的建立与求解

5.4.1 数据预处理

实验数据为女胎孕妇检测数据集，预处理步骤如下：

首先进行特征筛选，从染色体特性、测序质量、孕妇生理三个维度提取 13 个关键特征，其中染色体核心特征包括 21 号、18 号、13 号染色体的 Z 值及 GC 含量，测序质量特征涵盖原始读段数、参考基因组比对比例等，孕妇生理特征则包含年龄、BMI（身体质量指数）、体重等，确保特征维度全面覆盖判定相关影响因素。

针对部分样本中孕妇 BMI 等特征的缺失问题，采用均值填充法进行修复，以

全体样本的特征均值替代缺失值，避免缺失数据对模型训练的干扰。考虑到原始数据中正常样本与异常样本比例悬殊，通过 SMOTE 算法生成虚拟异常样本，实现类别平衡，处理后数据集样本量扩充至 1236 条，特征维度保持 13 维，正常与异常样本比例接近 1:1，消除类别不平衡对模型偏倚的影响。

最后对所有 13 个特征进行 Z-score 标准化，通过将特征转换为均值为 0、标准差为 1 的标准化数据，消除不同特征量纲带来的干扰，确保各特征在模型训练中权重公平。

5.4.2 模型构建与分析

（一）模型构建

基于预处理后的数据集，本研究选择两种经典集成学习算法构建分类模型，分别为随机森林与梯度提升树，模型参数经多次调试后确定最优配置：

随机森林：决策树数量设为 100，最大树深度设为 8，通过多棵决策树的投票机制降低过拟合风险；

梯度提升树：决策树数量设为 100，学习率设为 0.1，最大树深度 设为 3，通过迭代优化前一轮模型的误差提升分类精度。

为确保模型评估的客观性，采用分层抽样法将预处理后的数据集按 8:2 比例划分为训练集与测试集，其中训练集包含 548 条样本，测试集包含 137 条样本，分层抽样可保持训练集与测试集中正常、异常样本的比例与原始数据集一致，避免抽样偏差对评估结果的影响。

（二）模型性能分析

以 AUC 为核心评估指标，结合准确率、精确率、召回率综合判断模型性能，测试集上的评估结果显示：

随机森林模型：AUC 达 0.9242，准确率为 82%，异常样本召回率为 84%，即能准确识别 84%的异常样本，在三类评估指标中均表现最优；

梯度提升树模型：AUC 为 0.9133，准确率为 83%，异常样本召回率为 83%，虽准确率略高于随机森林，但核心指标 AUC 及异常样本召回率均低于前者。

从模型原理来看，随机森林的“并行集成”特性可有效降低单棵决策树的方差，对测序质量波动、孕妇生理参数个体差异等干扰因素的鲁棒性更强；而梯度

提升树的“串行迭代”特性虽对误差敏感，但易受极端样本影响，导致其在区分正常与异常样本时的能力略逊于随机森林。综合来看，随机森林模型为女胎染色体非整倍体异常判定的最优模型。

5.4.3 误差检验

采用混淆矩阵对两种模型的误差来源进行定量分析，混淆矩阵通过“真实标签-预测标签”的对应关系，直观反映模型的漏诊与误诊情况，具体结果如下：

（一）随机森林模型误差分析

随机森林混淆矩阵显示：在测试集的真实正常样本中，86 条被正确预测为正常，22 条被误判为异常（误诊率约 20.4%）；在真实异常样本中，91 条被正确预测为异常，17 条被误判为正常（漏诊率约 15.7%）。误诊样本主要源于部分正常样本的测序质量特征与异常样本接近，导致模型误分类；漏诊样本则多为染色体 Z 值接近正常阈值的轻度异常样本，模型对“边缘异常”的识别灵敏度仍有提升空间。

（二）梯度提升树模型误差分析

梯度提升树混淆矩阵显示：真实正常样本中 89 条正确预测、19 条误判（误诊率约 17.6%），真实异常样本中 90 条正确预测、18 条误判（漏诊率约 16.8%）。对比可知，梯度提升树的误诊率略低于随机森林，但漏诊率更高——这一结果与梯度提升树的“误差修正”逻辑相关，模型更倾向于将模糊样本判定为多数类（正常样本），导致异常样本的漏诊风险增加。

综合两种模型的误差情况，随机森林的漏诊率更低（15.7%＜16.8%），而漏诊率对产前筛查至关重要（漏诊异常样本可能导致严重临床后果），因此随机森林的误差分布更符合临床需求。

5.4.4 结果可视化

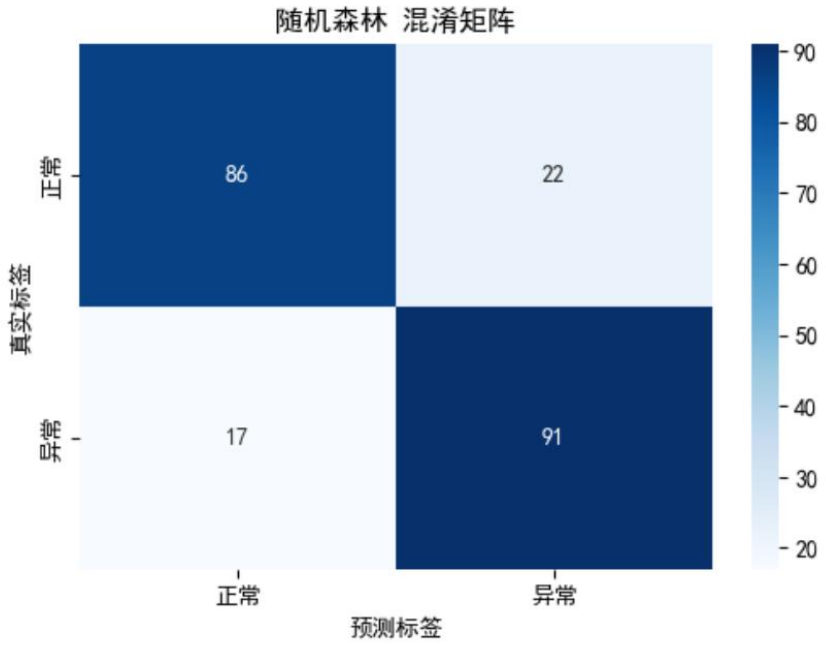

图 5-4-1 随机森林混淆矩阵

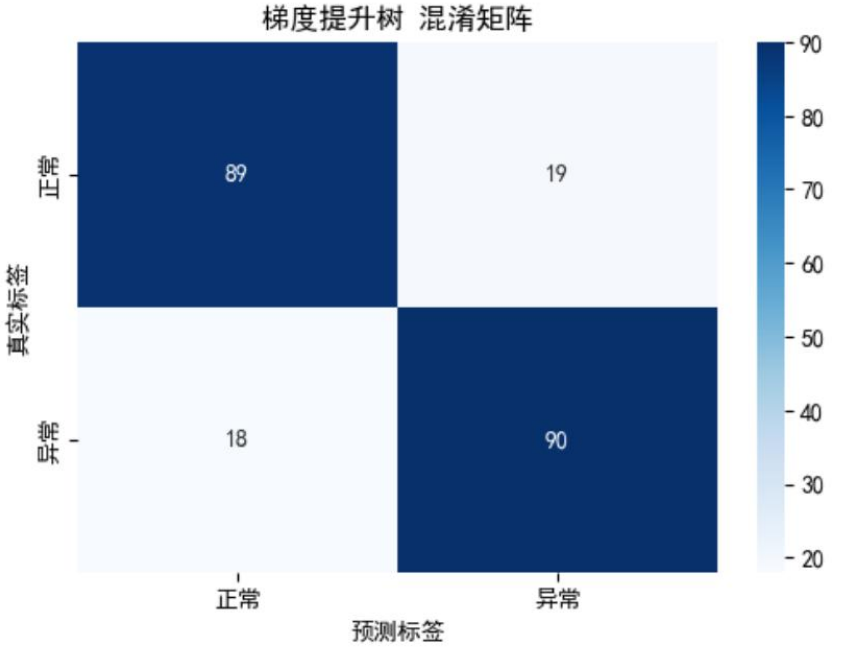

图 5-4-2 梯度提升树混淆矩阵

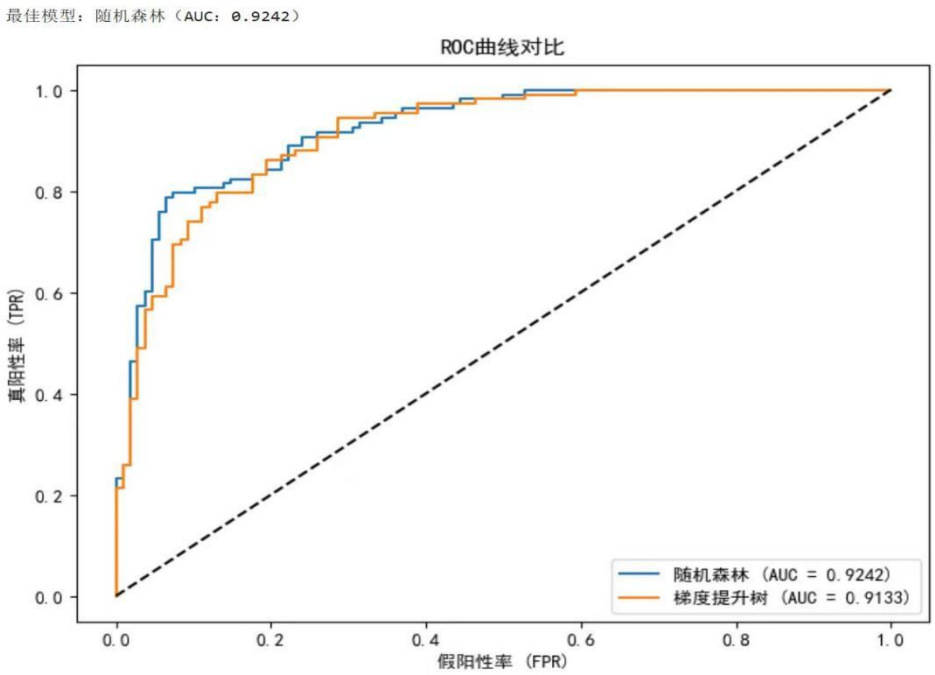

图 5-4-3ROC 曲线

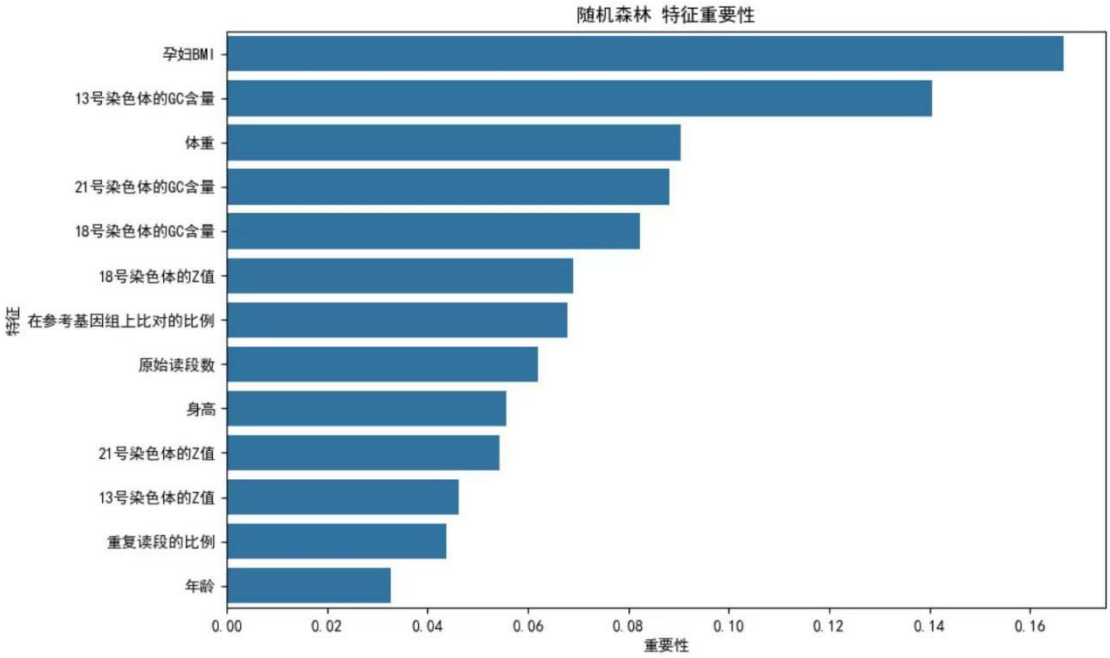

图 5-4-4 随机森林的特征重要性排序

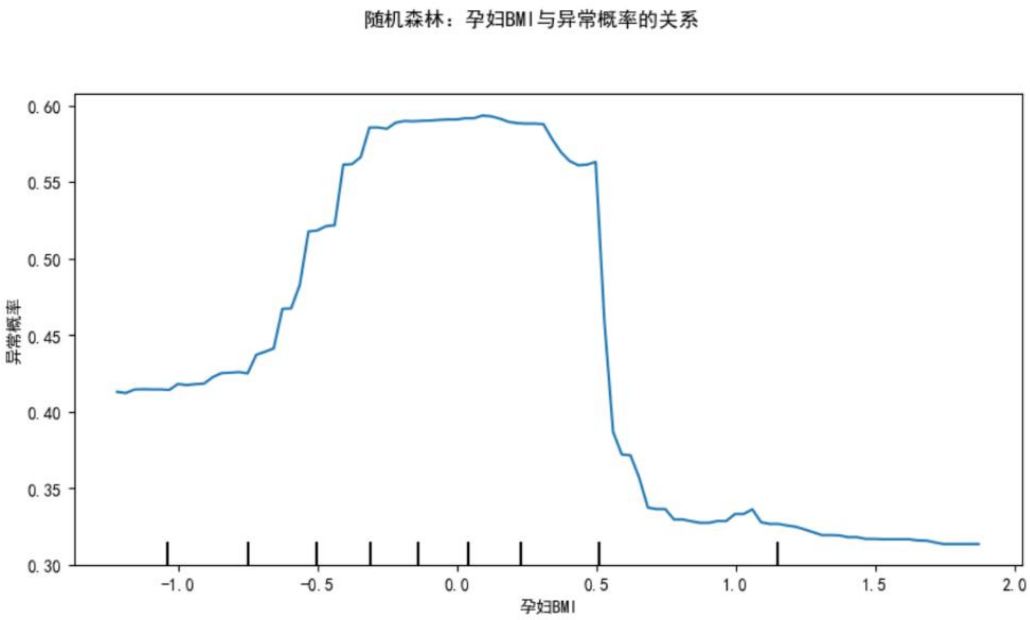

图 5-4-5 局部依赖图

分别对以上图像进行分析，图 5-4-1：真实正常样本中，86 条被正确预测为正常，22 条误判为异常；真实异常样本中，17 条误判为正常，91 条正确预测为异常。图 5-4-2：真实正常样本中，89 条正确预测为正常，19 条误判为异常；真实异常样本中，18 条误判为正常，90 条正确预测为异常。图 5-4-3 直观展示了模型的分类能力。随机森林的 ROC 曲线更接近左上角，AUC 值（0.9242）高于梯度提升树（0.9133），表明其在区分正常与异常样本方面表现更优。图 5-4-4 显示：孕妇 BMI、13 号染色体 GC 含量、体重为前三大重要特征。这表明孕妇生理特征与染色体自身特征对女胎染色体异常判定均具有显著影响，验证了多特征融合的必要性。图 5-4-5 展示了孕妇 BMI 与异常概率的关系。当孕妇 BMI 处于标准化后的-0.5 到 0.5 区间时，异常概率显著上升，提示 BMI 可能是女胎染色体异常的潜在影响因素，为临床关注孕妇体重管理提供了数据支持。

ROC 曲线以“假阳性率（误诊率）”为横轴、“真阳性率（召回率）”为纵轴，曲线越接近左上角，表明模型在相同误诊率下的召回率越高，区分正常与异常样本的能力越强。

从“ROC 曲线对比”图可知，随机森林的 ROC 曲线始终位于梯度提升树曲线的上方，且随机森林的 AUC（0.9242）高于梯度提升树（0.9133）：当假阳性率为 20%时，随机森林的真阳性率约为 84%，而梯度提升树的真阳性率约为 82%；

当假阳性率降至 15%时，随机森林的真阳性率仍能保持 80%以上，梯度提升树则降至 78%以下。这一结果进一步验证了随机森林在“低误诊-高召回”平衡上的优势，更适用于对灵敏度要求较高的产前筛查场景。

特征重要性反映各特征对模型分类决策的贡献度，重要性值越高，表明该特征对异常判定的影响越大。从“随机森林特征重要性”图可知，前三大关键特征依次为：

1.孕妇 BMI：重要性值最高，表明孕妇 BMI 是影响女胎染色体异常的核心生理因素；

2.13 号染色体 GC 含量：作为染色体自身特征，GC 含量直接反映染色体的碱基组成稳定性，异常样本的 13 号染色体 GC 含量往往偏离正常范围；

3.孕妇体重：重要性值仅次于 13 号染色体 GC 含量，与 BMI 共同构成孕妇生理状态的关键指标。

前三大特征分别来自孕妇生理维度（BMI、体重）与染色体核心维度（13 号染色体 GC 含量），这一结果印证了“多特征融合”的合理性——单一依赖染色体 Z 值的传统方法忽略了孕妇生理参数的影响，而本研究的多维度特征设计能更全面地捕捉异常信号，提升判定准确性。

5.4.5 结论

本研究针对女胎染色体非整倍体异常判定的痛点，提出“染色体核心特征-测序质量特征-孕妇生理特征”的多特征融合方法，通过系统的数据分析与建模，得出以下结论：

1.数据预处理流程有效解决了原始数据的关键问题：SMOTE 算法消除了类别不平衡对模型的偏倚，Z-score 标准化消除了量纲干扰，均值填充保障了数据完整性，为后续建模提供了高质量数据基础；

2.随机森林模型为最优判定模型：其 AUC（0.9242）、异常样本召回率（84%）均优于梯度提升树，且漏诊率更低（15.7%），能在控制误诊风险的同时，最大限度识别异常样本；

3.多特征融合显著提升判定性能：特征重要性分析表明，孕妇 BMI、13 号染色体 GC 含量等非传统指标对判定结果影响显著，相比传统单一 Z 值方法，多维

度特征能更全面捕捉异常信号，提升模型鲁棒性；

4.临床应用价值明确：基于随机森林的判定流程可输出量化的异常概率，为临床产前筛查提供可靠参考，有助于减少漏诊与误诊。

未来研究可进一步纳入孕妇既往妊娠史、家族遗传史等临床特征，扩大样本量优化模型参数，进一步提升对轻度异常样本的识别灵敏度，为女胎染色体异常产前筛查提供更精准的技术支持。

六、模型评价与推广

6.1 模型的优缺点

（一）优点：

1.分层次建模：从基础关联到多因素优化，逐步提升模型复杂度，贴合临床实际需求；

2.误差量化分析：通过蒙特卡洛模拟量化检测误差对结果的影响，为风险评估提供依据；

3．数据处理严谨：采用 SMOTE 算法平衡样本、Z-score 标准化消除量纲，提升模型稳健性；

4.可解释性强：通过特征重要性分析明确关键影响因素。

（二）缺点：

1.数据局限性：样本以高 BMI 群体为主，模型对低 BMI 群体的适用性需进一步验证；

2.假设简化：未考虑孕妇并发症、胎儿遗传背景等因素，可能影响模型普适性；

3.误差模型单一：仅模拟正态分布误差，未涵盖系统性误差（如测序技术偏差）。

6.2 模型的改进与推广

（一）改进方向

1.扩展数据维度：纳入妊娠期并发症、家族遗传史等临床数据，构建更全面的多因素模型；

2.优化误差模拟：结合实际测序误差分布（如偏态分布），提升风险评估的真实性；

3.动态模型构建：采用纵向数据模型（如 GEE）分析重复检测数据，捕捉个体浓度变化趋势

（二）推广价值

1.临床应用：可为不同 BMI 孕妇提供个性化检测时点建议（如肥胖孕妇尽早检测），降低漏诊风险；

2.技术支持：女胎异常判定模型可直接辅助临床医生解读检测报告，提升筛查效率；

3.研究拓展：方法可推广至其他染色体异常（如性染色体三体）的检测分析，为产前诊断提供通用框架。

七、参考文献

[1]李洁,王生兰, 王涛. NT 联合 NIPT、早期唐氏筛查及四维超声检查在胎儿染色体疾病筛查中的应用研究[J]. 临床医学进展, 2025, 15(3): 2369-2376.

[2]李乾. 基于Logistic增长模型和相关性分析的疫情预测[J]. 应用数学进展, 2022, 11(7): 4219-4227.

[3]向进勇, 王振华, 邓芸芸. 基于随机森林算法的机器学习分类研究综述[J]. 人工智能与机器人研究, 2024, 13(1): 143-152.

[4]Kwon, H.J., Goyal, A., Im, H., Lee, K., Yun, S.Y., Kim, Y.H., Lee, S., Lee, M.-G., Lee, H., Garg, R., Park, B., Choi, S., Joo, J., Bae, J.-S., Kim, M.-J., Lee, M.S. and Lee, S. (2017) Multiple z-Score Based Method for Noninvasive Prenatal Test Using Cell-Free DNA in Maternal Plasma. Open Journal of Genetics, 7, 1-8. https://doi.org/10.4236/ojgen.2017.71001